

Knowledge Embedding Based Graph Convolutional Network

WWW 2021

2021/5/18

1 Introduction

Motivation:

1. 传统的GCN方法主要假设在同质图上进行学习，忽略了KG中的relation蕴含的丰富的信息。
2. 传统的KGE方法没有考虑graph的结构信息
3. 将GCN和KGE结合的方法比如VR-GCN，COMPGCN等，在学习relation embedding的时候没有考虑entity embedding对relation embedding的影响

1 Introduction

Method:

为了解决上面的问题，提出了KE-GCN（Knowledge Embedding based Graph Convolution Network）

- 结合KGE模型，基于图卷积操作同时学习entity和relation embedding。
- 引入了得分函数，认为认为GCN传播的邻居信息是得分函数对于中心节点的梯度。

2 Method

2.1 重新审视GCN

GCN的原始公式 $m_v^{l+1} = \sum_{u \in \mathcal{N}(v)} h_u^l$

$$h_v^{l+1} = \sigma(W^l(m_v^{l+1} + h_v^l))$$

对于上面的式子,引入一个得分函数 f , 该得分函数计算edge存在的score, 对于已经存在的edge输出较大的值; 对于不存在的边输出较小的值。

如果假设得分函数 f 为: $f(h_u, h_v) = h_u^T h_v$

那么计算的消息 h_u 能够看做 f 是对中心实体 v 的梯度, 那么所有 h_u 加起来就成为下面的形式:

2 Method

$$m_v^{l+1} = \sum_{u \in \mathcal{N}(v)} h_u^l \quad \Rightarrow \quad m_v^{l+1} = \sum_{u \in \mathcal{N}(v)} \frac{\partial f(h_u^l, h_v^l)}{\partial h_v^l} = \frac{\partial (\sum_{u \in \mathcal{N}(v)} f(h_u^l, h_v^l))}{\partial h_v^l}$$

$$h_v^{l+1} = \sigma(W^l(m_v^{l+1} + h_v^l))$$

此时对于 $h_v + m_v$ 看做是learning rate为1，对 h_v 的梯度提升；目的是使scoring function f 的值最大。

通过修改为上面的形式，能够看到，它从新的角度说明了GCN做了什么，邻居信息是如何提供给中心节点的，是如何帮助中心节点获得更好的表示的。

2 Method

2.2 KE-GCN

基于前面的分析，作者提出了新的框架KE-GCN，核心两部分，更新实体表示以及更新关系表示：

$$\begin{aligned} m_v^{l+1} &= \sum_{(u,r) \in \mathcal{N}_{\text{in}}(v)} W_r^l \frac{\partial f_{\text{in}}(h_u^l, h_r^l, h_v^l)}{\partial h_v^l} \\ &+ \sum_{(u,r) \in \mathcal{N}_{\text{out}}(v)} W_r^l \frac{\partial f_{\text{out}}(h_v^l, h_r^l, h_u^l)}{\partial h_v^l} \\ h_v^{l+1} &= \sigma_{\text{ent}}(m_v^{l+1} + W_0^l h_v^l) \end{aligned}$$

更新实体

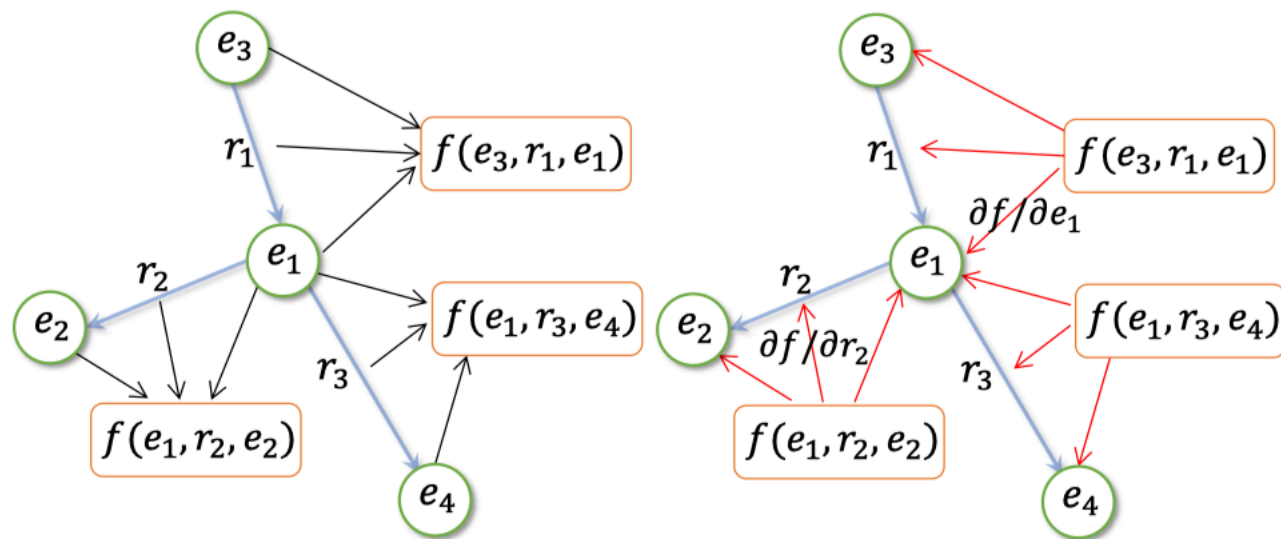
$$\begin{aligned} m_r^{l+1} &= \sum_{(u,v) \in \mathcal{N}(r)} \frac{\partial f_r(h_u^l, h_r^l, h_v^l)}{\partial h_r^l} \\ h_r^{l+1} &= \sigma_{\text{rel}}(W_{\text{rel}}^l (m_r^{l+1} + h_r^l)) \end{aligned}$$

更新关系

2 Method


2.2 KE-GCN

使用图示说明



消息传递过程；

首先计算得分函数，然后分别求导得到消息



消息聚合过程；

对于实体和关系都有一个聚合函数

3 Experiment

在实验的时候，对于KE-GCN，主要是引入不同的得分函数 f ，该得分函数使用不同的KGE方法，并且为了简化模型，对于in, out, self-loop都使用了相同的 W 和相同的得分函数 f 。

使用了一系列的KGE方法：

- TransE [3]: For $h_u, h_r, h_v \in \mathbb{R}^d$,

$$f(h_u, h_r, h_v) = -\|h_u + h_r - h_v\|_2^2. \quad (16)$$

- DistMult [41]: For $h_u, h_r, h_v \in \mathbb{R}^d$.

$$f(h_u, h_r, h_v) = h_u^T \text{diag}(h_r) h_v. \quad (17)$$

- TransH [36]: For $h_u, h_v \in \mathbb{R}^d, h_r \in \mathbb{R}^{2d}$, and $h_{r1}, h_{r2} \in \mathbb{R}^d$,

$$f(h_u, h_r, h_v) = -\|h'_u + h_{r2} - h'_v\|_2^2, \quad (18)$$

$$h'_u = h_u - h_{r1}^T h_u h_{r1}, \quad (19)$$

$$h'_v = h_v - h_{r1}^T h_v h_{r1}, \quad (20)$$

$$h_r = [h_{r1}; h_{r2}], \quad (21)$$

- TransD [10]: For $h_u, h_v, h_r \in \mathbb{R}^{2d}$, and $h_{u1}, h_{u2}, h_{v1}, h_{v2}, h_{r1}, h_{r2} \in \mathbb{R}^d$,

$$f(h_u, h_r, h_v) = -\|h'_u + h_{r2} - h'_v\|_2^2, \quad (22)$$

$$h'_u = h_{u1} + h_{u2}^T h_{u1} h_{r1}, \quad (23)$$

$$h'_v = h_{v1} - h_{v2}^T h_{v1} h_{r1}, \quad (24)$$

$$h_u = [h_{u1}; h_{u2}], h_v = [h_{v1}; h_{v2}], h_r = [h_{r1}; h_{r2}], \quad (25)$$

where $[\cdot; \cdot]$ means concatenation of two vectors.

- RotatE [24]: For $h_u, h_r, h_v \in \mathbb{C}^d$,

$$f(h_u, h_r, h_v) = -\|h_u \circ h_r - h_v\|_2^2, \quad (26)$$

where \circ denotes element-wise product and the modulus of any element in h_r is 1, i.e. $|h_r[i]| = 1 \forall i \in \{1, 2, \dots, d\}$. The norm of complex vector is defined as $\|v\|_p = \sqrt[p]{\sum |v_i|^p}$.

- QuatE [47]: For $h_u, h_r, h_v \in \mathbb{H}^d$,

$$f(h_u, h_r, h_v) = h_u \otimes h_r \cdot h_v, \quad (27)$$

3 Experiment

预测任务:

1. Knowledge Graph Alignment
2. Knowledge Graph Entity Classification

知识图谱对齐, 主要是匹配两个不同知识图谱中的实体和关系;
知识图谱实体分类, 包括多分类和多标签分类

Datasets		#Entities	#Relations	#Triplets
DBP _{ZH-EN}	Chinese	66,469	2,830	153,929
	English	98,125	2,317	237,674
DBP _{JA-EN}	Japanese	65,744	2,043	164,373
	English	95,680	2,096	233,319
DBP _{FR-EN}	French	66,858	1,379	192,191
	English	105,889	2,209	278,590

图谱对齐

Datasets	AM	WN	FB15K
#Entities	1,666,764	40,551	14,904
#Relations	133	18	1,341
#Triplets	5,988,321	145,966	579,654
#Labeled	1,000	31,943	13,445
#Classes	11	24	50

实体分类

3 Experiment

图谱对齐实验结果:

Models	DBP _{ZH-EN}			DBP _{JA-EN}			DBP _{FR-EN}		
	MRR	H@1	H@10	MRR	H@1	H@10	MRR	H@1	H@10
MTransE*[7]	0.364	30.8	61.4	0.349	27.9	57.5	0.335	24.4	55.6
IPTransE*[49]	0.516	40.6	73.5	0.474	36.7	69.3	0.451	33.3	68.5
JAPE*[25]	0.490	41.2	74.5	0.476	36.3	68.5	0.430	32.4	66.7
AlignE*[26]	0.581	47.2	79.2	0.563	44.8	78.9	0.599	48.1	82.4
GCN-Align*[35]	0.549	41.3	74.4	0.546	39.9	74.5	0.532	37.3	74.5
MuGCN*[6]	0.611	49.4	84.4	0.621	50.1	85.7	0.621	49.5	87.0
AliNet*[27]	0.628	53.9	82.6	0.645	54.9	83.1	0.657	55.2	85.2
R-GCN*[21]	0.564	46.3	73.4	0.571	47.1	75.4	0.570	46.9	75.8
W-GCN [22]	0.553	43.6	73.8	0.554	41.2	74.7	0.541	39.8	74.4
VR-GCN [42]	0.501	38.0	73.3	0.470	35.2	72.2	0.495	36.1	75.1
KBGAT [16]	0.582	48.0	77.3	0.582	47.6	77.7	0.593	47.4	80.9
CompGCN[30]	0.605	49.4	81.2	0.614	50.4	82.2	0.625	50.5	85.0
CompGCN [†]	0.628	52.8	81.1	0.629	52.8	81.5	0.641	52.6	85.4
KE-GCN	0.664	56.2	84.2	0.670	57.0	85.2	0.683	57.2	88.5

3 Experiment

实体分类实验结果:

Models	AM	WN
GCN	86.2 ± 1.4	53.4 ± 0.2
R-GCN	89.3^*	55.1 ± 0.6
W-GCN	$90.2 \pm 0.9^*$	54.2 ± 0.5
KBGAT	85.7 ± 1.7	53.7 ± 1.1
CompGCN	$90.6 \pm 0.2^*$	55.9 ± 0.4
KE-GCN	91.2 ± 0.2	57.8 ± 0.5

Models	P@1	P@5	N@5
GCN	86.1 ± 0.3	69.0 ± 0.3	82.7 ± 0.2
R-GCN	91.7 ± 0.6	73.0 ± 0.4	89.5 ± 0.6
W-GCN	91.2 ± 0.6	72.8 ± 0.3	88.6 ± 0.5
KBGAT	90.5 ± 0.7	72.4 ± 0.8	87.5 ± 0.8
CompGCN	92.5 ± 0.1	74.0 ± 0.3	90.1 ± 0.2
KE-GCN	94.3 ± 0.2	74.7 ± 0.2	91.6 ± 0.2

3 Experiment

对于KE-GCN使用不同得分函数的实验：

KE-GCN (X)	MRR	H@1	H@10
X = TransE	0.669 \pm 0.002	55.9 \pm 0.2	87.5 \pm 0.2
X = TransH	0.673 \pm 0.002	56.1 \pm 0.2	87.7 \pm 0.2
X = DistMult	0.640 \pm 0.002	52.4 \pm 0.2	84.7 \pm 0.2
X = TransD	0.660 \pm 0.002	54.2 \pm 0.2	87.6 \pm 0.1
X = RotatE	0.673 \pm 0.002	56.0 \pm 0.3	88.2 \pm 0.2
X = QuatE	0.683 \pm 0.002	57.2 \pm 0.3	88.5 \pm 0.2

在实体对齐任务上，性能越好的得分函数获得了越好的效果；

KE-GCN (X)	AM	WN
X = TransE	91.2 \pm 0.2	57.8 \pm 0.5
X = TransH	90.5 \pm 0.3	57.4 \pm 0.3
X = DistMult	89.5 \pm 0.4	56.4 \pm 0.1
X = TransD	90.1 \pm 0.2	57.1 \pm 0.2
X = RotatE	90.6 \pm 0.4	56.6 \pm 0.3
X = QuatE	91.0 \pm 0.4	56.9 \pm 0.3

但是在实体分类任务上，简单的TransE获得了最好的效果；